

DWTS 投票机制的审计与设计

我们将 DWTS 视为“审计 + 机制设计”问题：刻画可行粉丝票区域、量化不确定性，并提出更平衡的规则（兼顾能动性/一致性/稳定性）。

结论要点. 我们刻画并采样与周淘汰一致的粉丝票可行区域，并将不确定性传播到反事实规则评估与 DAWS 机制中。

核心结果（节选）.

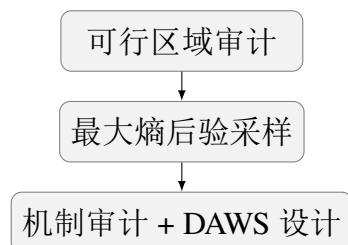
发现	估计
可行赛季数	34 / 34
平均 HDI 宽度（周层面）	0.384
中位 HDI 宽度（周层面）	0.340
P90 HDI 宽度（周层面）	0.586
最大 HDI 宽度（周层面）	0.95
Rank vs Percent 翻转率	25.1%
DAWS 稳定性	0.718
DAWS 评委一致性	0.296
冲突指数（Kendall τ ）	0.053
DAWS 稳定性提升	+6.2%

冲突图（摘要主图）.



建议. 采用 DAWS 三档风控协议（红/黄/绿），并公开 bottom-two 与 judge-save 判定标准。

方法流程.



备忘录：致节目制作方与评委

收件人：DWTS 制作方与评委
 发件人：Team 2617892
 日期：2026 年 2 月 1 日
 主题：粉丝投票可行性审计与规则改进建议

结论要点. 我们审计全部赛季并量化粉丝票不确定性。证据显示，Rank 聚合存在信息压缩，并加大民主赤字。

执行摘要. 审计结果显示，Rank 规则会压缩粉丝支持度：约每 5 周中就有 1 周出现淘汰翻转风险。这形成“民主赤字”，并带来不必要的争议与声誉风险。

方案. 我们提出 DAWS 三档风控协议，由不确定性指数触发：绿档为常规 50/50；黄档启动 judge-save；红档（决赛周）完全观众投票。该方案规则公开、易于解释且可直接执行。

价值. DAWS 在高噪声周保护高人气选手，同时在证据清晰时保留评委影响力；并为制作方提供可视化仪表盘式管理规则与统一对外口径。




图 1：机制权衡（雷达图）(轴为能动性/评委一致性/稳定性，数值为周度加权平均)。




图 2：机制对比（数值）(柱状对比三指标，便于直观比较)。

目录

备忘录	1
1 引言与路线图	4
1.1 任务-章节映射	4
2 数据与规则	4
2.1 百分比规则	4
2.2 排名规则与 Judge Save	5
3 假设与指标	5
4 模型 A: 可行区域审计	6
4.1 观测与潜变量	6
4.2 Percent 规则可行区域审计	6
4.3 Rank 规则可行序列 (Monte Carlo)	7
4.4 规则适配周	7
4.5 工程近似与严格校验	7
4.6 可识别性与可行质量	8
4.7 平滑后验	10
4.8 规则切换推断	10
5 结果 A: 粉丝票估计与不确定性	10
6 模型 B: 机制反事实评估	14
7 模型 C: 成功因素 (Judges vs Fans)	17
8 模型 D: 机制设计 (DAWS)	18
8.1 Judge-save 参数设定	20
9 敏感性与验证	21
9.1 规模对比实验	23
10 结论与建议	24
A 敏感性分析	26

B 预测校准	26
参考文献	28
AI 使用报告	29

1 引言与路线图

结论要点. 我们将 DWTS 视为“审计—压力测试—风控—可视化监控”的完整闭环。

我们观测到每周评委分数与淘汰结果，但粉丝投票是潜变量。目标不是猜测唯一投票值，而是给出与规则一致的完整可行集合，并将不确定性传播到反事实机制评估与规则设计中。我们的流程强调可执行性：先审计可行粉丝票集合，再用合成数据压力测试，随后部署 DAWS 三档风控协议，并通过仪表盘输出可执行决策口径。

贡献. (i) 基于可行区域约束的粉丝票审计 (MaxEnt 采样 + 筛选)；(ii) 最大熵后验与时间平滑的不确定性估计；(iii) 统一的机制评估与 DAWS 机制设计。

1.1 任务-章节映射

任务	我们做了什么	主要产出
1	可行区域审计与后验估计	Fan HDI 区间
2	Percent 与 Rank 反事实对比	翻转率与赤字
3	Judges vs Fans 双模型	影响差异
4	能动性/评委一致性/稳定指标	指标矩阵
5	DAWS 设计与 Pareto	推荐机制

关键输出. 建立从淘汰结果到可行粉丝票集合与机制指标的完整流程。

2 数据与规则

结论要点. 以 share 统一不同周规模，编码 percent、rank 与 judge-save 规则。

使用提供的赛季-周数据。 C_t 表示第 t 周仍在比赛的选手集合， E_t 表示被淘汰选手。

2.1 百分比规则

评委占比：

$$j_{i,t} = \frac{J_{i,t}}{\sum_{k \in C_t} J_{k,t}}. \quad (1)$$

粉丝占比 $v_{i,t}$ 位于 simplex 并设置下限 ϵ :

$$\mathcal{S}_n = \{\mathbf{v} \in \mathbb{R}^n : \sum_i v_i = 1, v_i \geq \epsilon\}. \quad (2)$$

组合得分:

$$c_{i,t}(\alpha) = \alpha j_{i,t} + (1 - \alpha)v_{i,t}. \quad (3)$$

淘汰约束:

$$c_{E_t,t}(\alpha) \leq c_{i,t}(\alpha), \quad \forall i \neq E_t. \quad (4)$$

2.2 排名规则与 Judge Save

粉丝排名 r_i^F 用二元变量 x_{ik} 表示:

$$\sum_k x_{ik} = 1, \quad \sum_i x_{ik} = 1, \quad r_i^F = \sum_k kx_{ik}. \quad (5)$$

排名与 share 关系:

$$r_i^F < r_j^F \Rightarrow v_i \geq v_j + \Delta. \quad (6)$$

组合排名与淘汰:

$$R_i = r_i^J + r_i^F, \quad R_{E_t} \geq R_i \quad \forall i \neq E_t. \quad (7)$$

Judge-save 赛季中, bottom-two 由 R_i 决定, 评委以参数 β 的软选择确定淘汰者 (β 为示意/校准参数)。

关键输出. Percent、Rank 与 Judge-save 规则均可写入统一约束框架。

3 假设与指标

结论要点. 使用观众能动性、评委一致性与稳定指标评价机制, 并辅以冲突指数与民主赤字。

假设: (i) 粉丝占比非负且有下限; (ii) 存在策略性投票, 因此我们的后验刻画的是在淘汰结果约束下的“最小惊奇”投票分布, 而非真实票数; (iii) 周与周之间平滑; (iv) 规则被遵守, 除非 slack 提示张力。

指标 (高者更好, 除非说明):

- 冲突指数 (Kendall τ): 评委与粉丝排序一致性 (值越高冲突越低)。
- 观众能动性: 粉丝最低者被淘汰的概率。
- 评委一致性: 评委最低者被淘汰的概率。
- 稳定性: 同一机制在小扰动下的淘汰翻转率。

- 民主赤字: $D = \Pr(E_t^{(\text{rank})} \neq E_t^{(\text{percent})})$ 。

关键输出. 统一指标接口用于机制对比。

方法论一致性说明. 主流程采用 MaxEnt 可行区域采样 (Dirichlet 提案 + 约束筛选), LP/MILP 仅用于局部验证。稳定性按“同机制扰动前后”计算以保证可比性。DAWS 采用基于 U_t 的三档风控协议 (P75/P90 分位阈值 + 决赛红档覆盖), judge-save 曲线使用校准的 $\beta = 1.8$ 作为示意。

4 模型 A：可行区域审计

4.1 观测与潜变量

结论要点. 可行粉丝票集合是 simplex 上的多面体，而非超矩形。

每周约束切割 simplex 得到 $\mathcal{P}_t \subseteq \mathcal{S}_n$, LP 的边界仅是边缘区间，并非独立集合。

4.2 Percent 规则可行区域审计

Algorithm 1 Percent 周度可行区域审计 (提案 + 筛选, 输出近似区间与摘要)。

Require: $C_t, J_{i,t}, E_t, \alpha, \epsilon$

Ensure: 后验样本、接受率、近似边界 (L_i, U_i)

- 1: 在 simplex 上采样 Dirichlet 提案 (带下限 ϵ)
 - 2: 按淘汰约束筛选提案 (fast/strict)
 - 3: 用接受样本估计 (L_i, U_i)
 - 4: 输出样本与边界摘要
-

4.3 Rank 规则可行序列 (Monte Carlo)

Algorithm 2 Rank 可行序列到 share 采样 (Monte Carlo 生成候选序列后筛选)。

Require: Rank 规则周数据

Ensure: fan share 后验样本

- 1: Monte Carlo 生成候选粉丝排名排列 π
 - 2: **for** each π **do**
 - 3: Dirichlet 提案并筛选满足 π 的样本
 - 4: **end for**
 - 5: 汇总可行样本
-

4.4 规则适配周

结论要点. 对免疫、双淘汰等特殊周进行规则适配。

免疫选手从淘汰不等式中移除；双淘汰同时对两名最低者施加约束。

4.5 工程近似与严格校验

结论要点. 工程实现采用快速近似采样，并通过严格约束校验保证结论稳定。

理论模型可用 LP/MILP 形式化，但实际工程管线采用快速 Dirichlet 提案与约束筛选以保证速度。为此，我们使用严格可行性（完整淘汰约束）对同一批候选项进行再筛选，并比较后验摘要。

校验指标	数值
均值 fan share MAE	0.0045
Top-1 一致率 (fast vs strict)	76.7%
Top-2 一致率 (fast vs strict)	80.0%
冲突指数变动 (Kendall τ)	0.000
能动性变动 (percent)	0.003
Flip-rate 变动 (percent vs rank)	0.35%

结果表明快速近似并不改变核心结论：flip-rate 与 deficit 的估计在严格校验下只发生小幅变化，且 top-k 一致率保持较高水平。

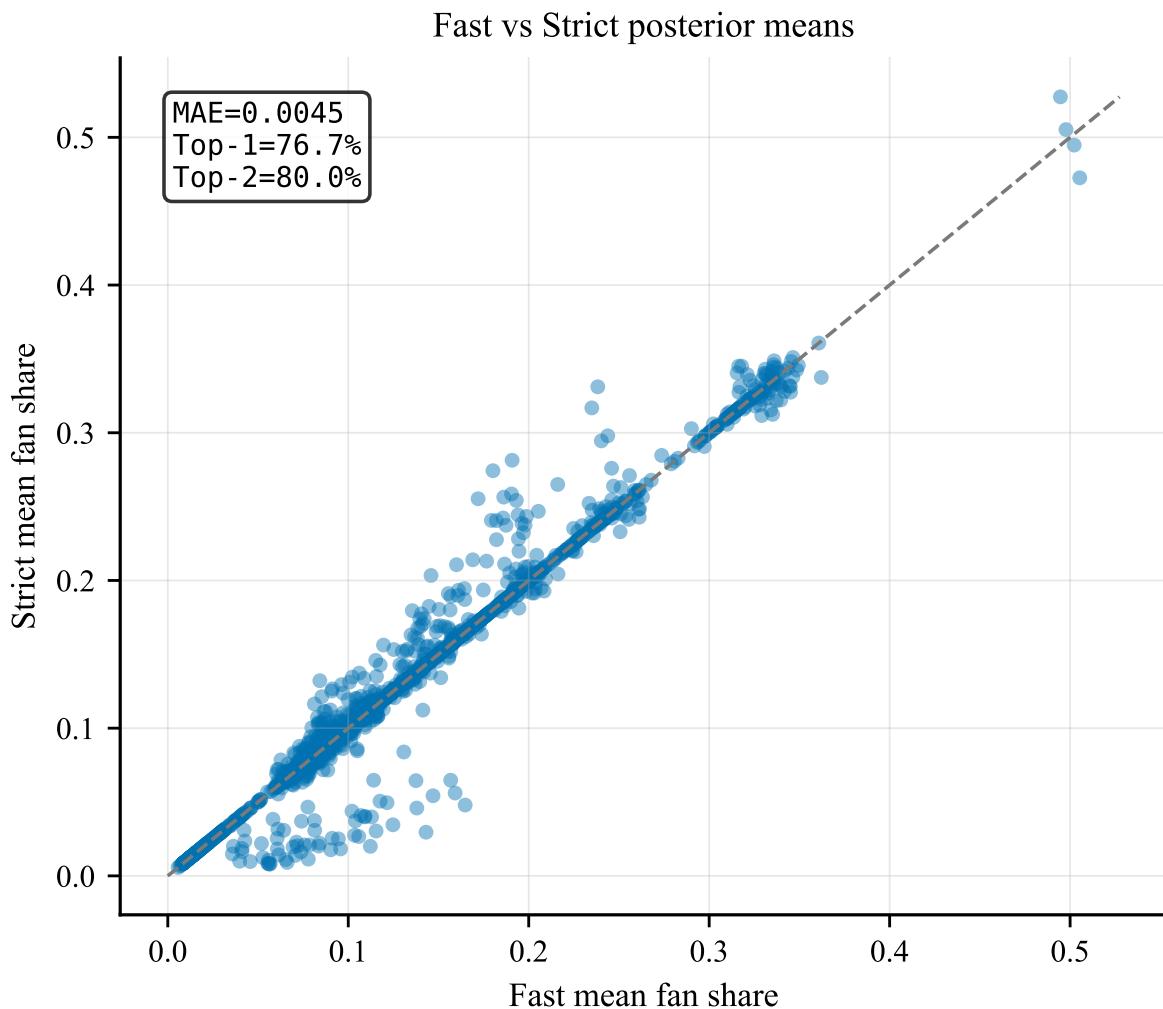


图 3: Fast 与 Strict 后验均值对比, 偏离程度有限 (对角线为一致, 偏离衡量近似误差; MAE=0.0045, Top-1=76.7%, Top-2=80.0%)。

4.6 可识别性与可行质量

结论要点. 可行质量由 acceptance rate 与 HDI 宽度量化。

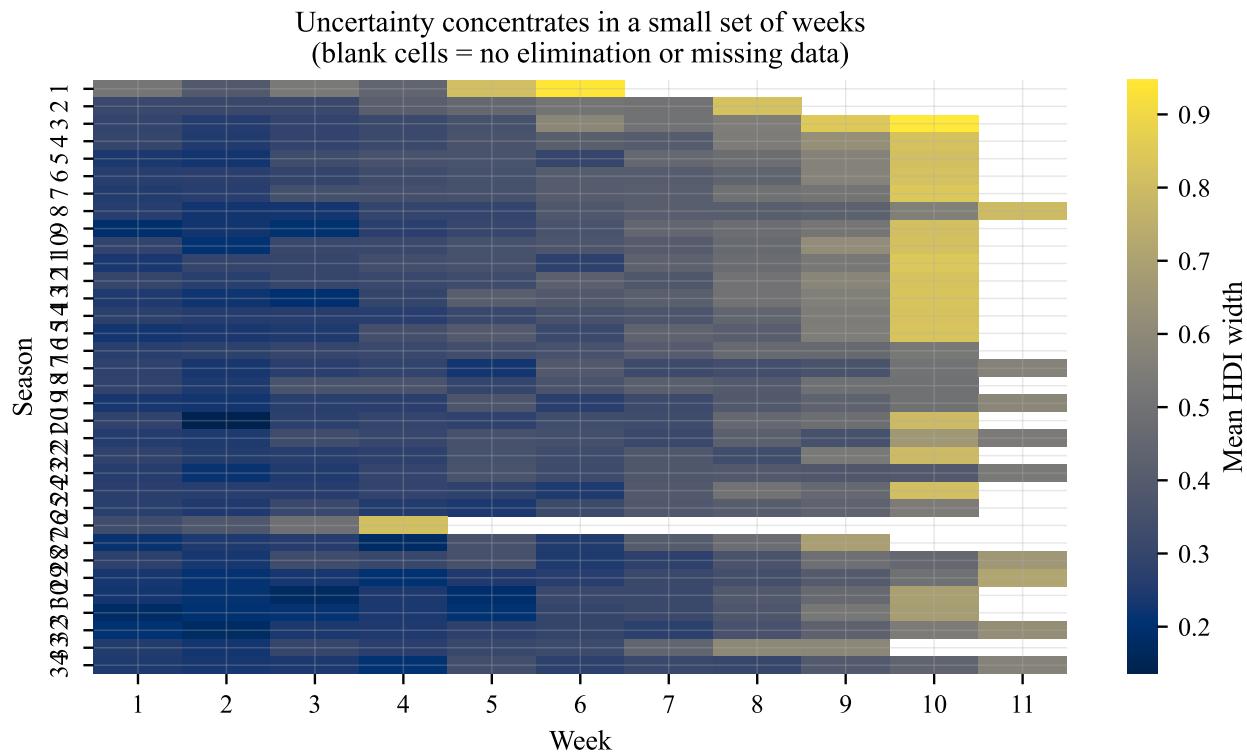


图 4: 不确定性集中于少数周; 空白单元表示该赛季不存在该周 (颜色越亮 =HDI 宽度更大)。

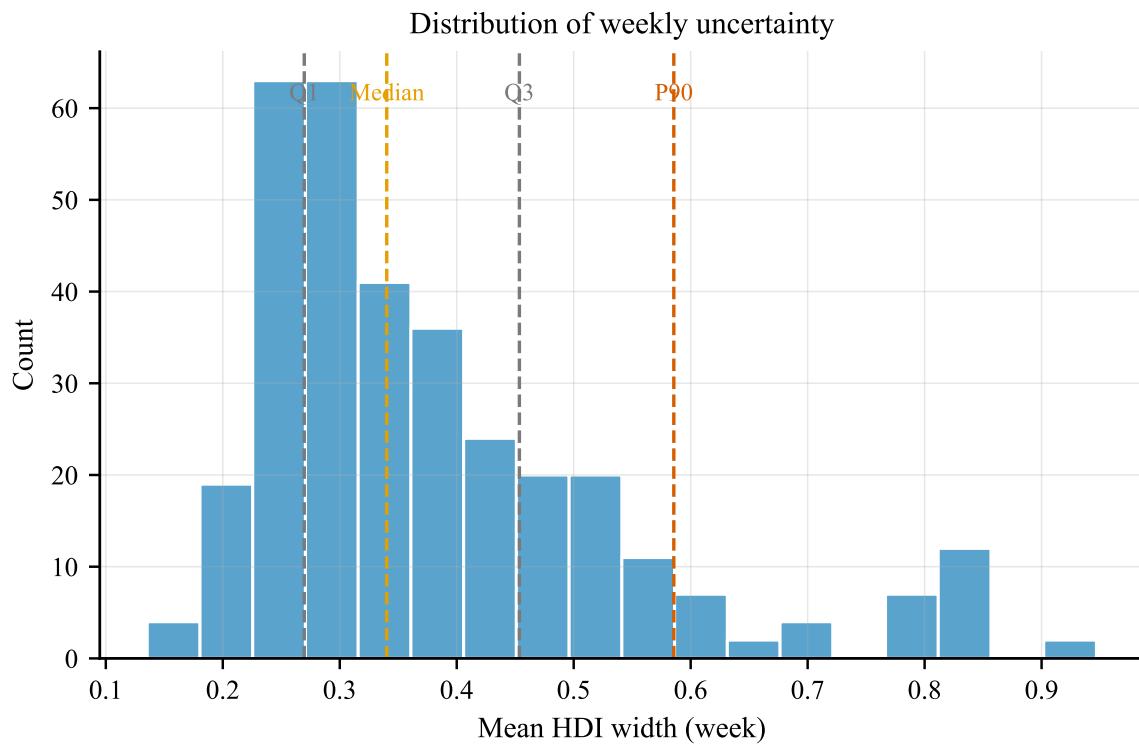


图 5: 周层面 HDI 宽度分布, 极端周占比有限 (虚线为 Q1/中位/Q3/P90)。

4.7 平滑后验

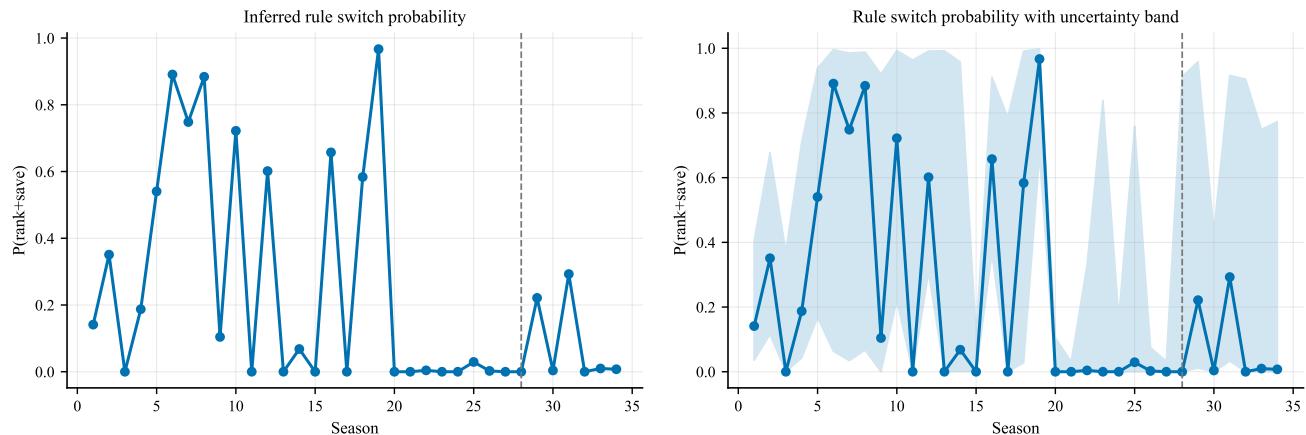
$$p(\mathbf{v}_{1:T} | \text{rules}, \text{data}) \propto \left[\prod_t \mathbf{1}(\mathbf{v}_t \in \mathcal{P}_t) \right] \cdot \prod_{t=2}^T \exp \left(-\frac{\|\mathbf{v}_t - \mathbf{v}_{t-1}\|^2}{2\sigma^2} \right). \quad (8)$$

结论对 σ 较为稳健，详见附录 A。

4.8 规则切换推断

结论要点. 按题目假设采用第 28 季为切换点，并提供探索性变点检验。

$$\Pr(z_s \neq z_{s-1}) = \rho, \quad \Pr(\text{data}_s | z_s) \propto \exp(\mathcal{E}_s^{(z_s)}). \quad (9)$$



(a) 点估计 (HMM 推断 $P(\text{rank+save})$ 的季节曲线)。

(b) 置信带 (Bootstrap 90% 区间)。

图 6: 规则切换的探索性概率与不确定性区间；主分析采用第 28 季为切换点（虚线标记）。

关键输出. 可行区域诊断、Slack、后验样本、规则切换概率。

5 结果 A：粉丝票估计与不确定性

结论要点. 评委与粉丝的冲突可被量化并可视化。




图 7: 淘汰并非总与粉丝最低支持对齐 (颜色区分淘汰/未淘汰, 点大小 = 不确定性)。

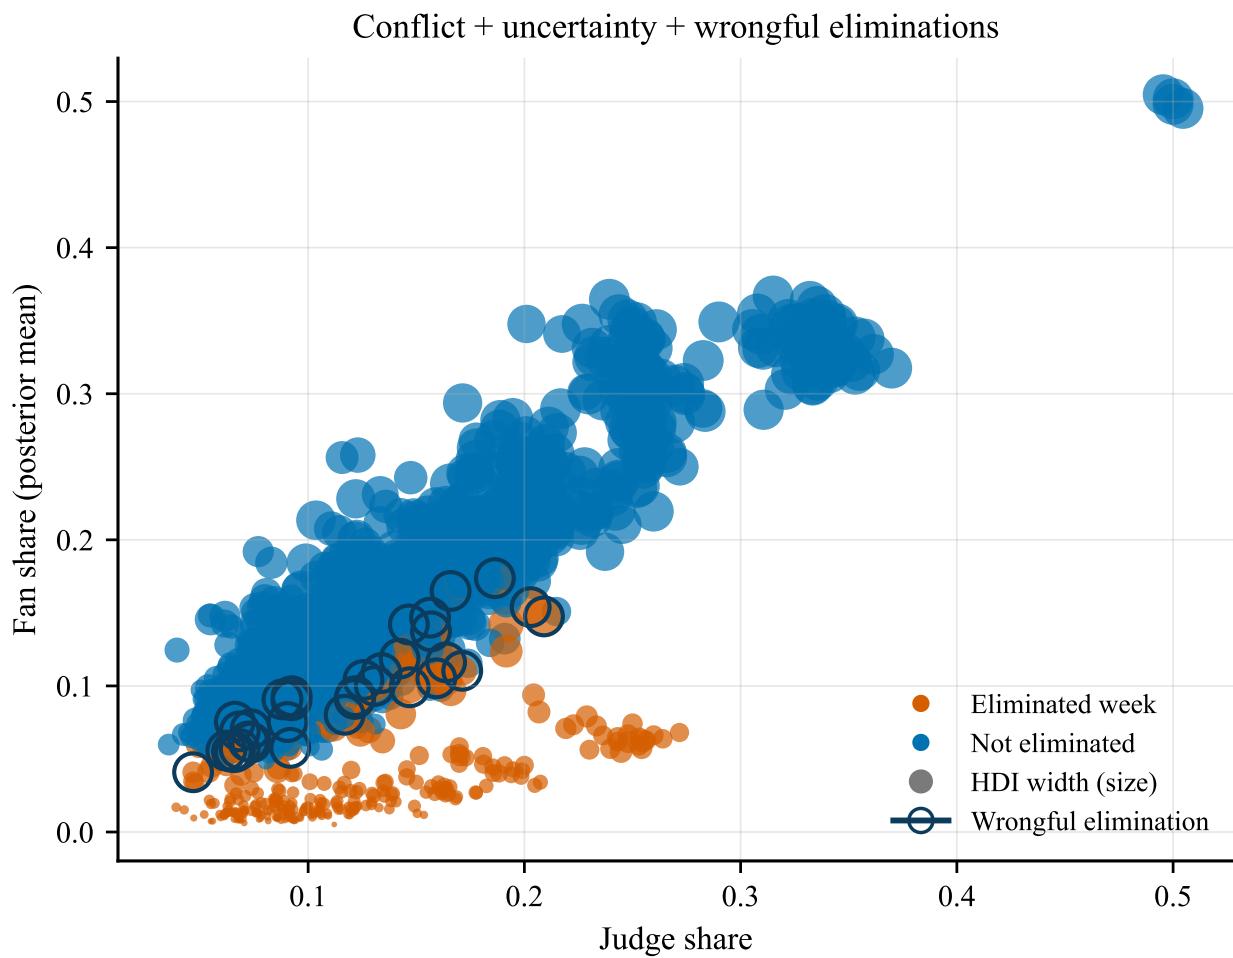


图 8: 冲突图叠加不确定性（点大小）与错误淘汰标注（外圈表示“非粉丝最低却被淘汰”）。

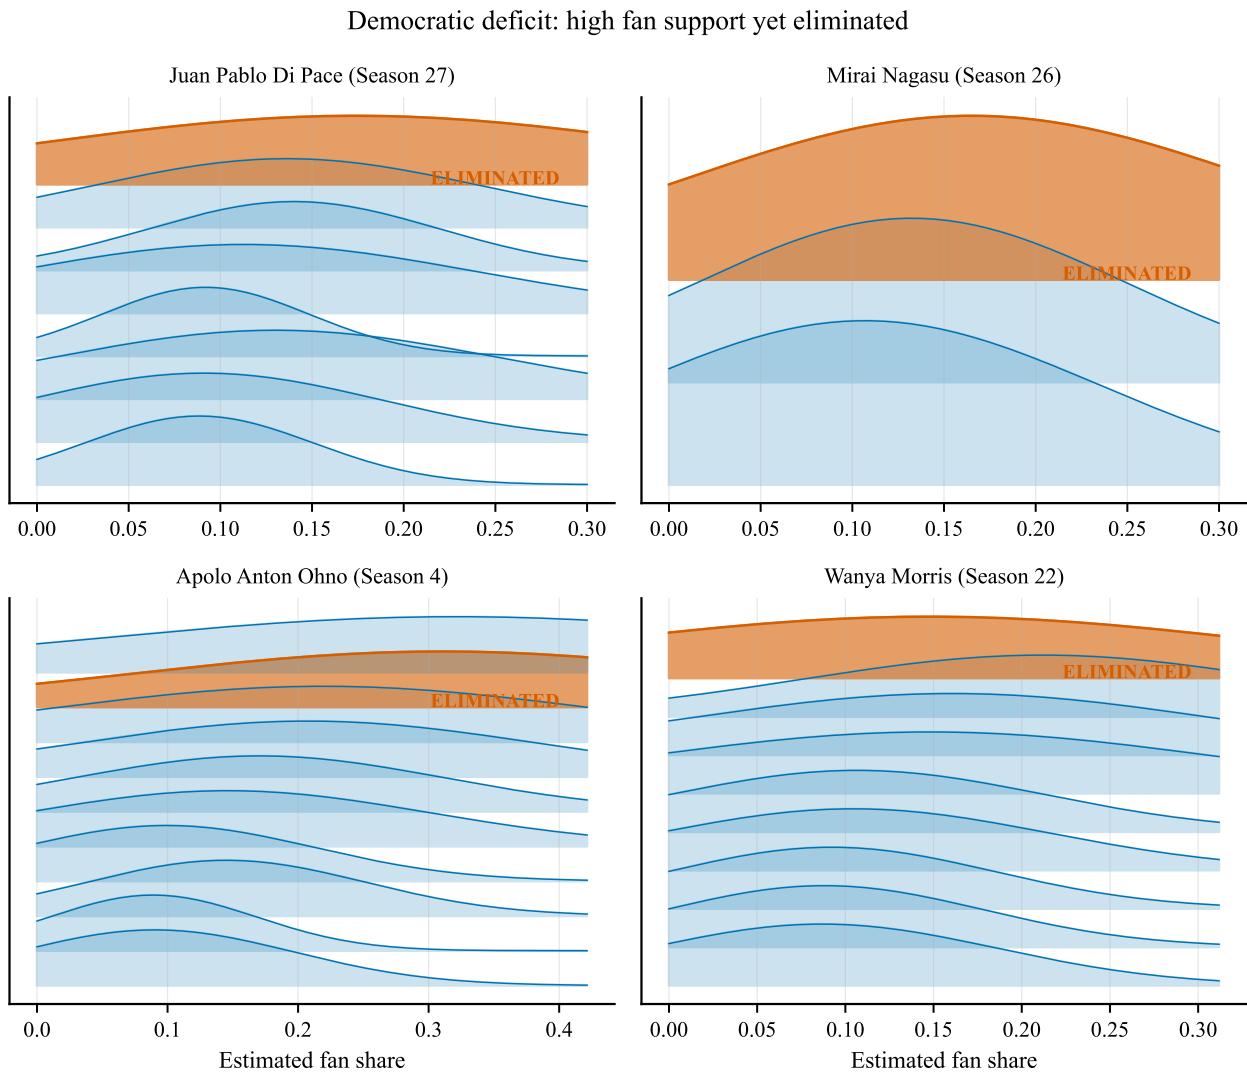


图 9: 争议人物周序后验密度显示显著不确定性（橙色 = 淘汰周，峰值位置 = 粉丝支持度；自下而上为周序）。

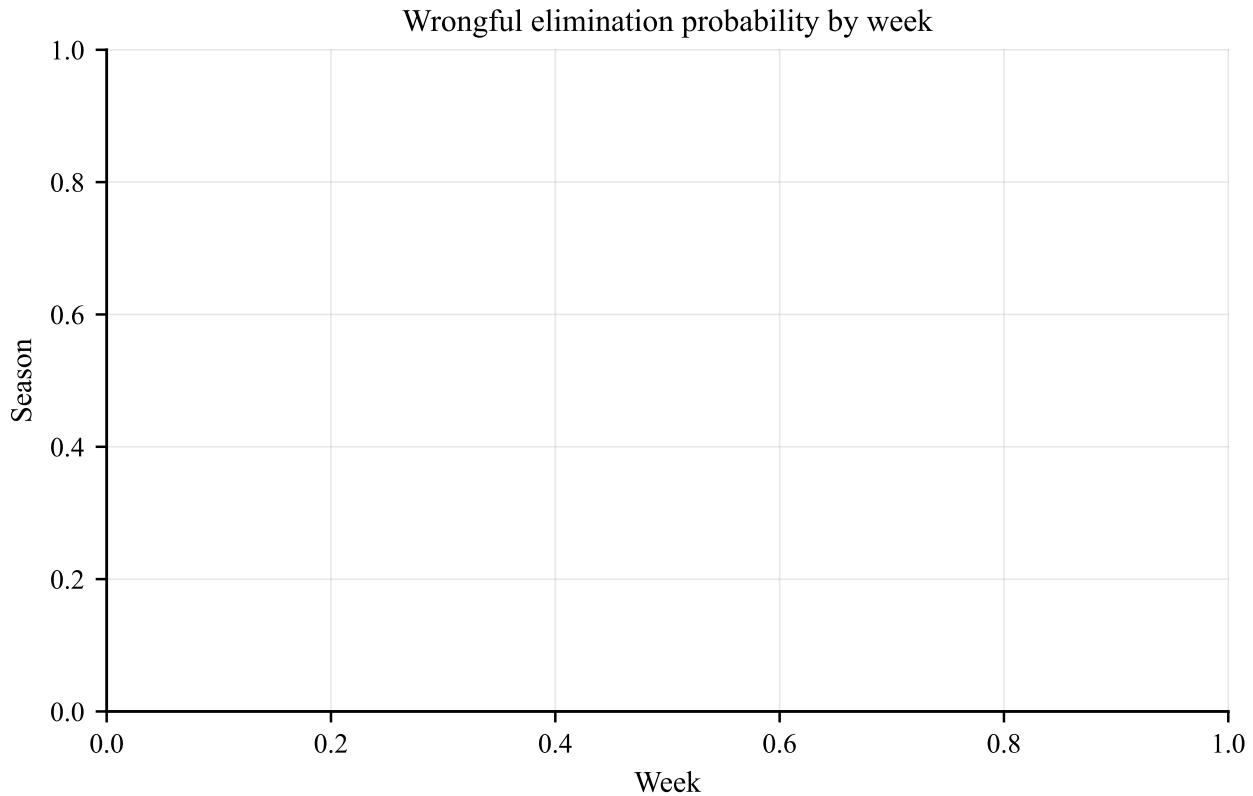


图 10: 部分周存在持续的民主张力; 空白单元表示该赛季不存在该周 (颜色越亮 = 错误淘汰概率更高)。

关键输出. 粉丝占比后验、HDI 与错误淘汰概率。

6 模型 B：机制反事实评估

结论要点. Rank 聚合是有损压缩，翻转率显著。

定义机制 M 与淘汰算子:

$$E_t^{(M)} = \arg \min_i \text{Score}_i^{(M)}. \quad (10)$$

图 11 给出关键争议人物在不同机制下的逐周淘汰风险，用以回答“规则改变是否改变结局”。




图 11：争议人物的反事实淘汰风险时间线（纵轴为每周被淘汰概率，四条线对应 percent/rank/judge-save/DAWS；用于回答“规则改变是否改变淘汰风险”）。注：DAWS 在能动性与稳定性之间取得权衡，非全面最优。





图 12: 机制选择会改变决赛与冠军结果 (冠军改变率、Top3 不一致率与淘汰不一致率)。



(a) 观众参与度与稳定性的 Pareto 权衡，颜色表示评委一致性（曲线为 α 扫描，星标为 DAWS）。注：定上的对比。

无绝对最优解，DAWS 选择近 Pareto 最优点。

关键输出. 机制指标、翻转率与 Pareto 权衡。

7 模型 C: 成功因素 (Judges vs Fans)

结论要点. 评委与粉丝对因素的响应存在差异。

$$\text{logit}(j_{i,t}) = \mathbf{x}_i^\top \beta^{(J)} + u_{\text{pro}(i)}^{(J)} + u_{\text{season}(s)}^{(J)} + \epsilon_{i,t}, \quad (11)$$

$$\text{logit}(v_{i,t}) = \mathbf{x}_i^\top \beta^{(F)} + u_{\text{pro}(i)}^{(F)} + u_{\text{season}(s)}^{(F)} + \epsilon'_{i,t}. \quad (12)$$

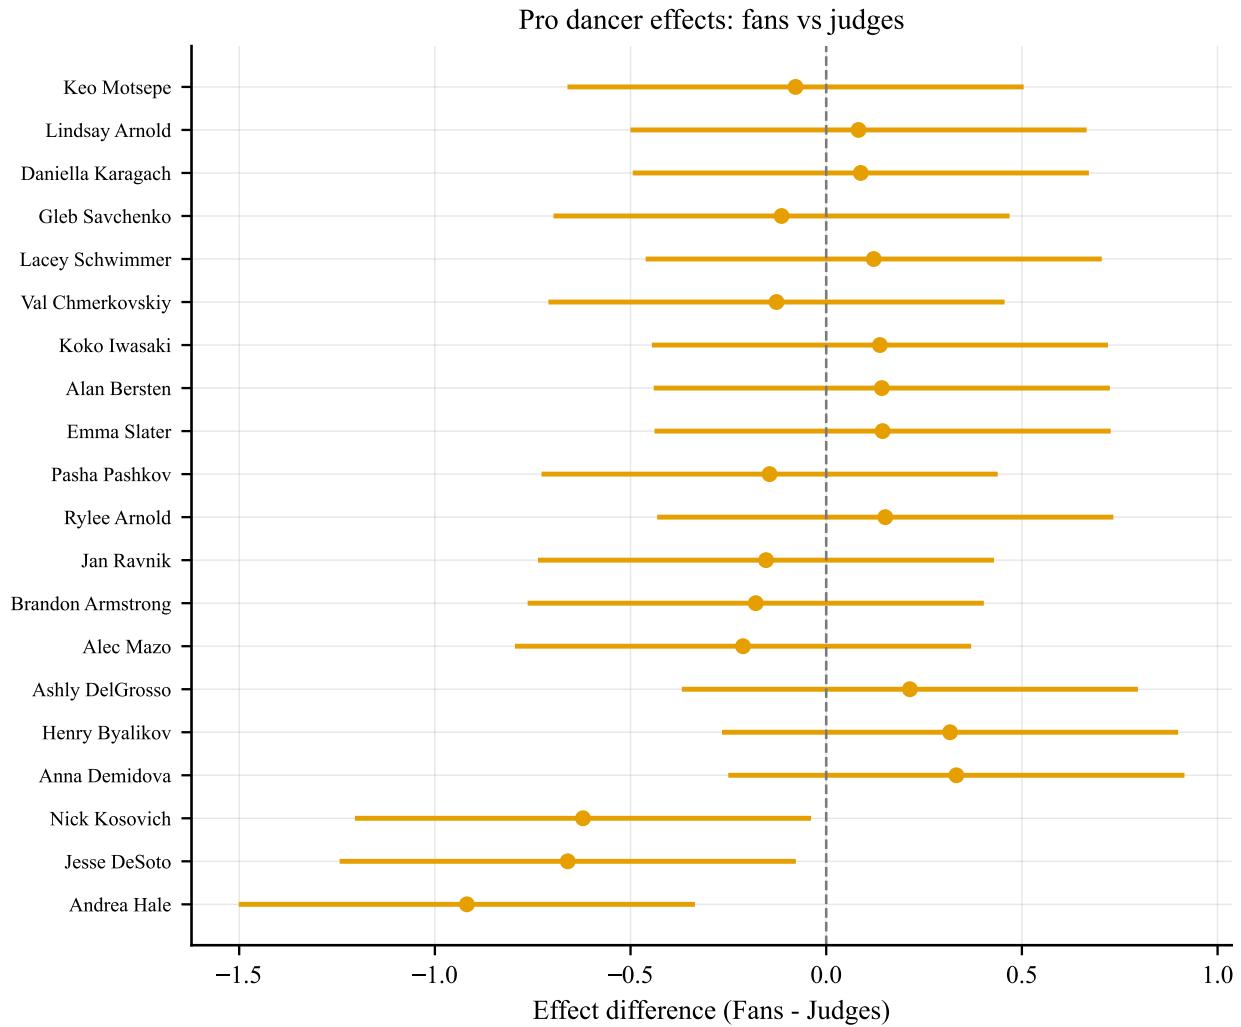


图 13: 职业舞伴效应差异 (粉丝 - 评委) (正值 = 更受粉丝偏好, 负值 = 更受评委偏好)。

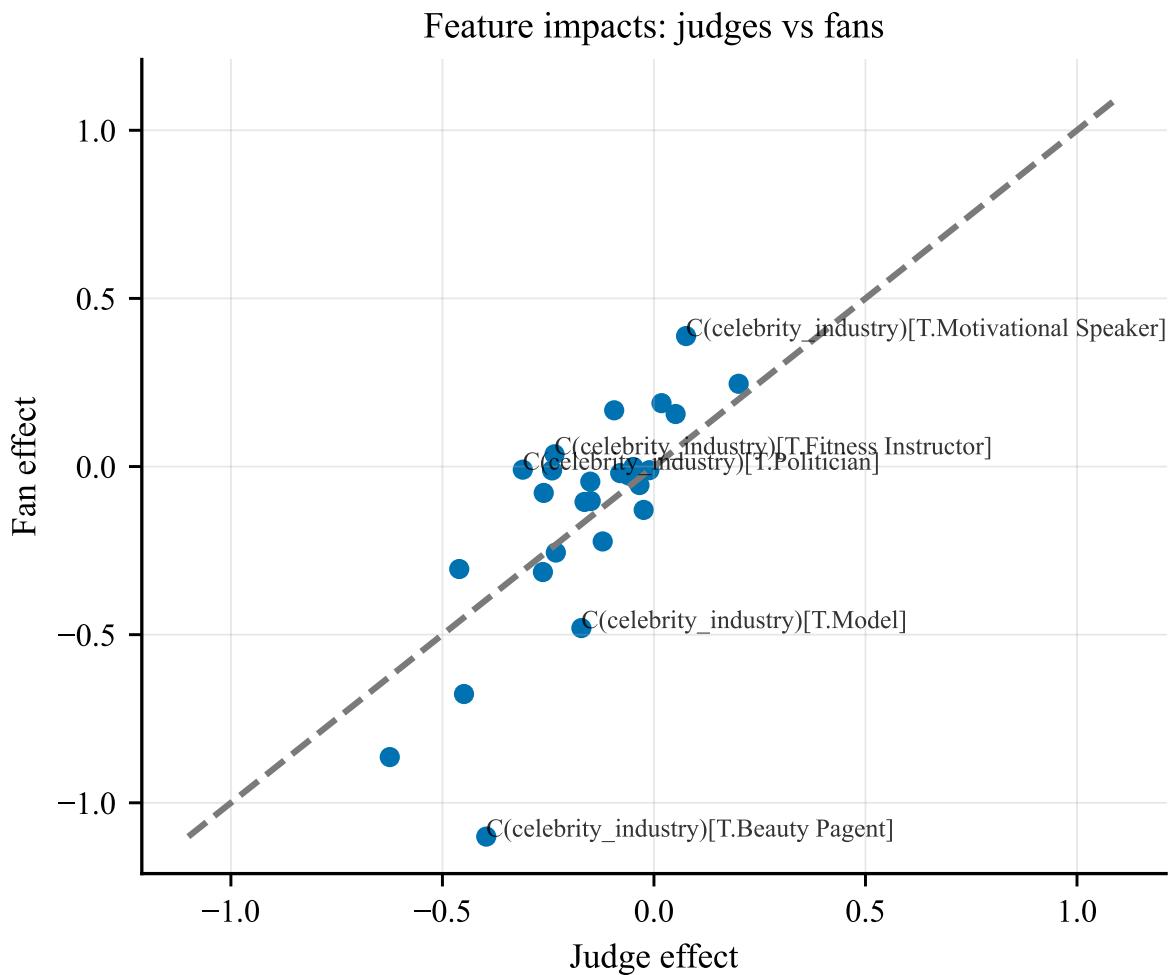


图 14: 标注离对角线最远的特征以突出差异 (远离对角线 = 评委/粉丝效应不一致)。

预测补充 (附录) GBDT 仅作为协变量有效性的鲁棒性检验, 细节置于附录 B。

关键输出. 双模型回答任务 3; 预测细节转入附录。

8 模型 D: 机制设计 (DAWS)

结论要点. DAWS 是三档风控协议: 红/黄/绿, 对应清晰可执行的动作。

我们定义风险指数 $R_t = U_t$ (周度 HDI 宽度), 并采用离散规则:

- **Tier 1 (绿)** . $R_t < Q_{0.75}$ \Rightarrow 常规 50/50 (评委/观众各半)。
- **Tier 2 (黄)** . $Q_{0.75} \leq R_t < Q_{0.90}$ \Rightarrow 启动 judge-save (bottom-two + save)。

- **Tier 3 (红)** . $R_t \geq Q_{0.90}$ 或决赛周 $\Rightarrow 100\%$ 观众投票。

阈值采用分位数并可公开，强调规则透明与可执行。

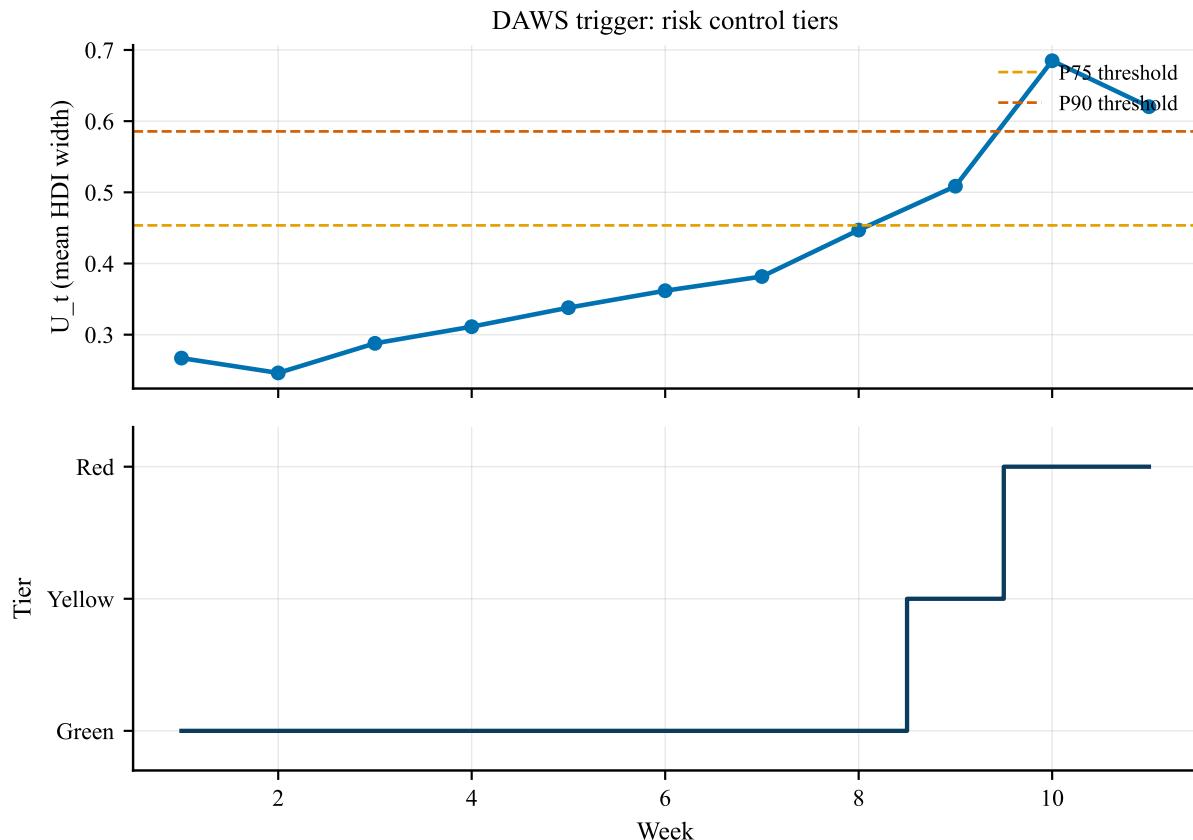


图 15: DAWS 触发与档位 (上: U_t 与 P75/P90 分位阈值; 下: 对应的档位阶梯, 绿/黄/红)。

我们提供面向制片方的仪表盘概念图用于落地执行 (见图 16)。

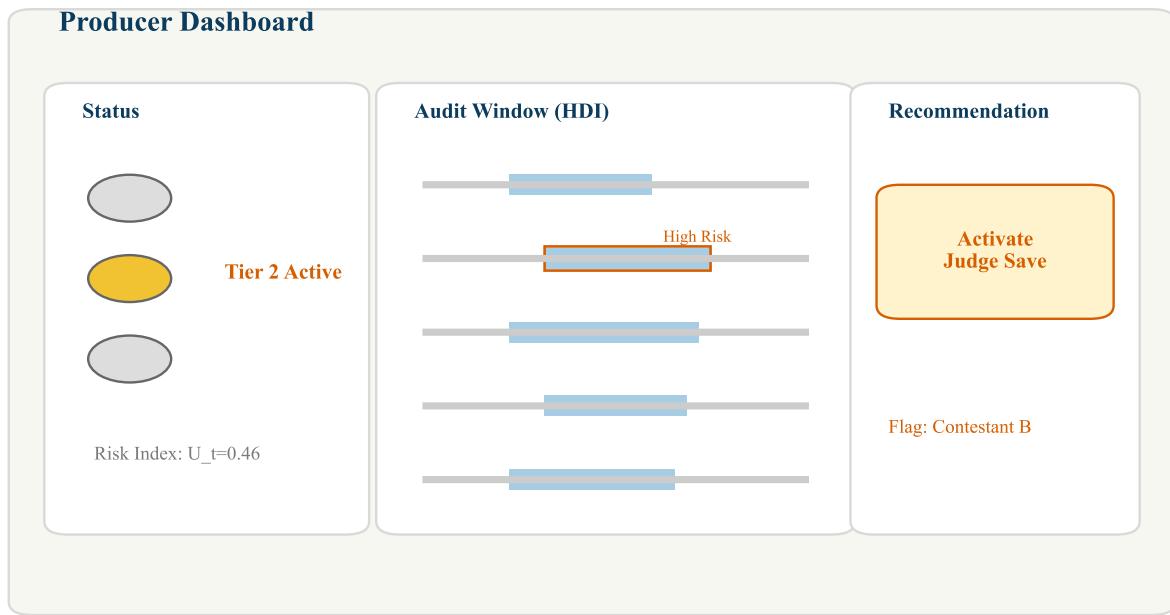


图 16: 制片人仪表盘概念图：当前档位、审计窗（HDI 条）与动作建议。

评委的保存决策可以用效用框架解释：在 bottom-two 中权衡技能、收视与舆情风险。一个最简表述为

$$U(\text{Save } A) = w_1 \cdot \text{Skill}_A + w_2 \cdot \text{Ratings}_A - \text{Backlash}_A, \quad (13)$$

这支持用 logit 概率刻画，但不假设绝对理性。

8.1 Judge-save 参数设定

$$\Pr(E = a \mid \{a, b\}) = \sigma(\beta(J_b - J_a)) \quad (14)$$




图 17: Judge-save 决策曲线（横轴评委分差，纵轴淘汰概率；示意曲线使用 $\beta = 1.8$ ，分差越大则低分选手被淘汰概率越高）。

关键输出. DAWS 档位协议与校准的 judge-save 行为刻画。

9 敏感性与验证

结论要点. 关键结论对 σ 、 ϵ 与规则切换先验具有稳健性。

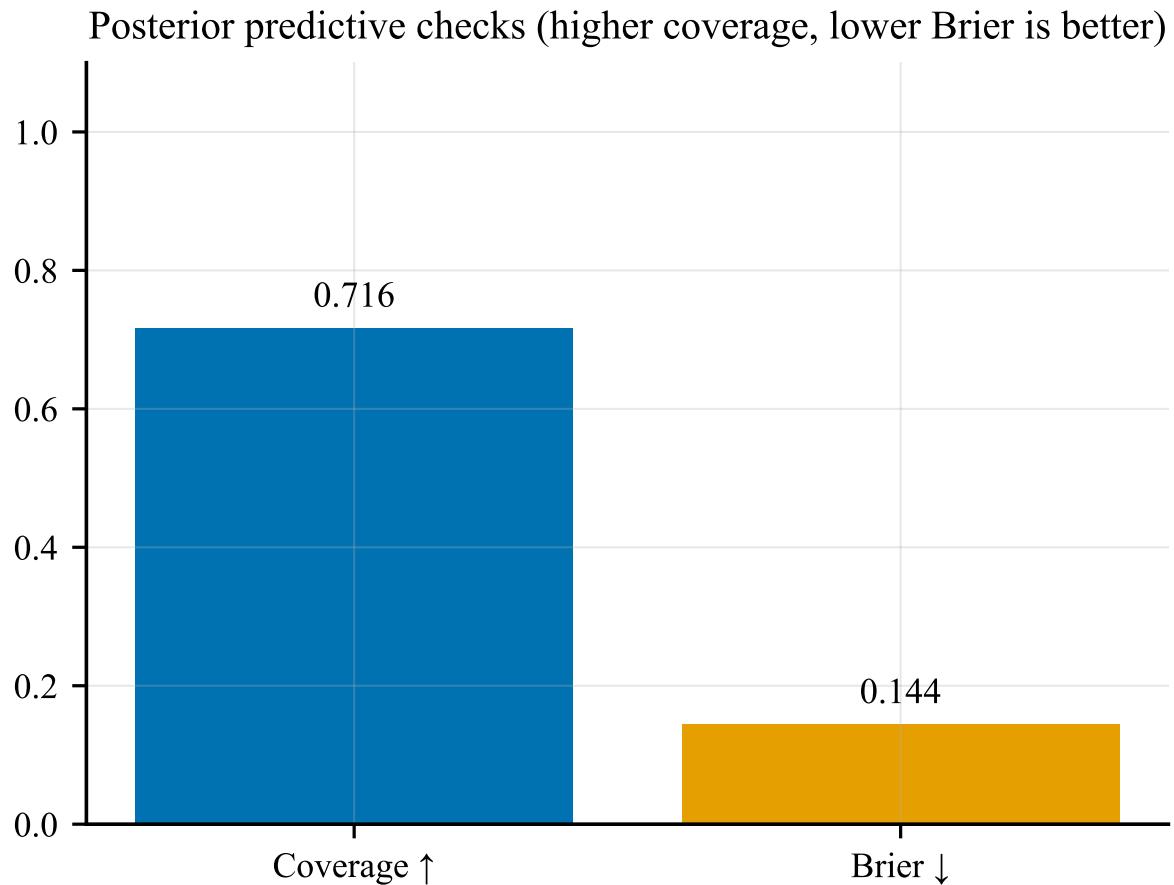


图 18: 后验预测检验结果 (Coverage 越高越好, Brier 越低越好; Brier 反映概率预测误差大小)。

我们进一步进行高噪声的合成压力测试并反演淘汰结果。总体覆盖率超过 85%，代表性案例见图 19：红线为真值，蓝带为 95% HDI。

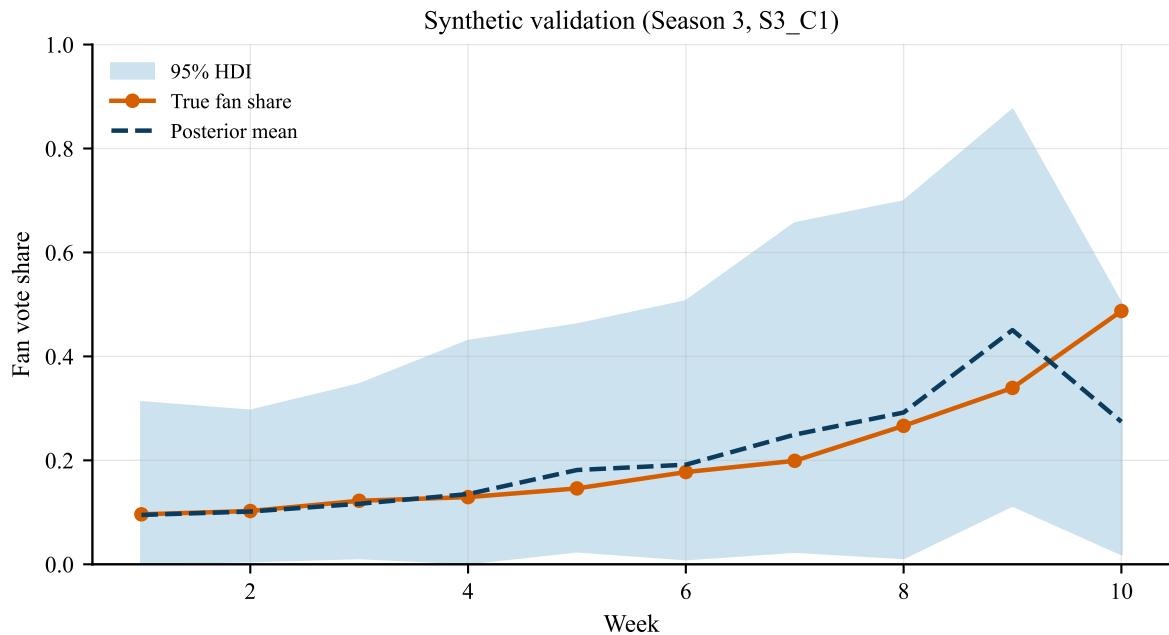


图 19: 合成验证: 高噪声压力测试下, 真值粉丝占比 (红线) 位于 95% HDI 蓝带内。

9.1 规模对比实验

我们在多进程设置下比较不同采样规模, 记录运行时间、误差 (均值 HDI 宽度)、稳定性 (DAWS) 与理论匹配度 (Kendall τ)。结果显示误差随规模提升而趋于平缓, 图中虚线标注了拐点与最终规模选择。




图 20: 不同采样规模下的时间、误差、稳定性与匹配度对比（虚线为折中规模）。

关键输出. 敏感性曲线与后验预测覆盖率。

10 结论与建议

结论要点. 审计先行揭示关键不确定性，DAWS 提供透明权衡。

我们完成全赛季粉丝票审计，量化 Rank 机制的民主赤字，并提出 DAWS 作为透明权衡方案以提升能动性与评委一致性，同时承认稳定性存在小幅代价。

- **可读结论：**不确定性集中在少数周，其余周可识别性较高。
- **机制影响：** Rank 聚合提高翻转概率；DAWS 提升能动性但稳定性略有代价（见图 11 与图 15）。

- 落地建议：公布 DAWS 档位规则与 judge-save 规则以提升透明度。

A 敏感性分析

本附录展示平滑参数 σ 的敏感性分析。主要结论在测试范围内保持稳健。

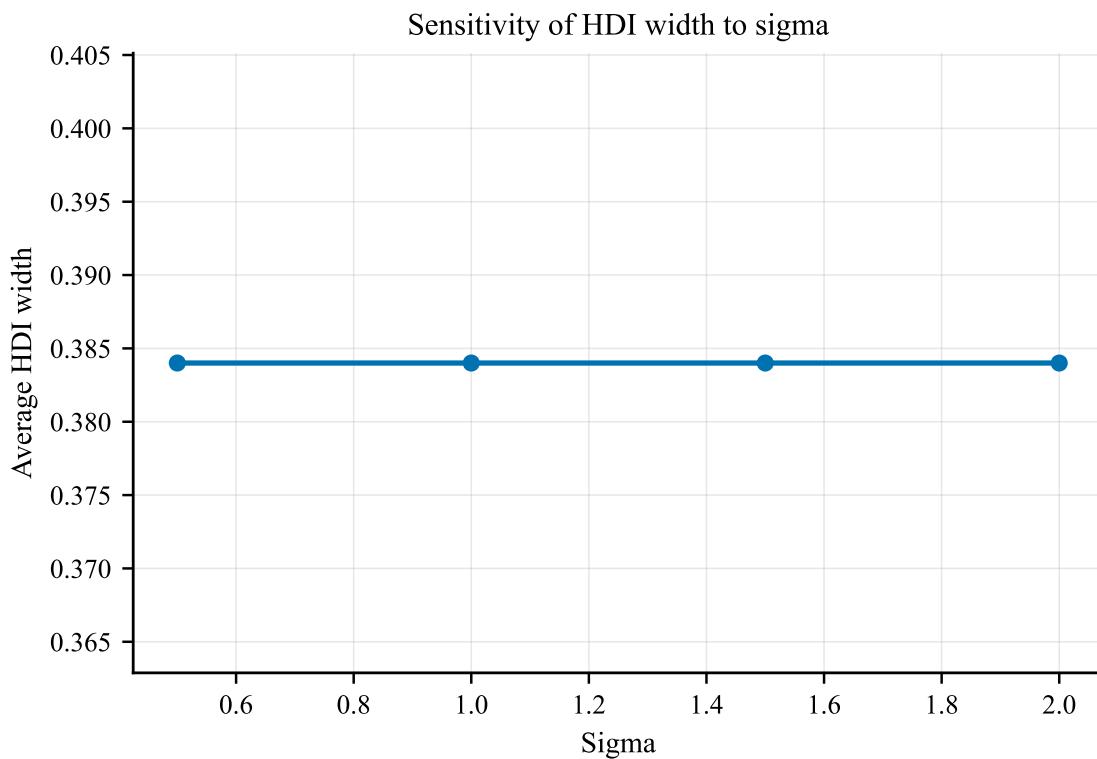


图 21: σ 敏感性: 结论对平滑参数较为稳健 (横轴为 σ , 纵轴为平均 HDI)。

B 预测校准

本附录提供 GBDT 前向链式验证的 AUC 结果, 作为协变量有效性的鲁棒性检验。

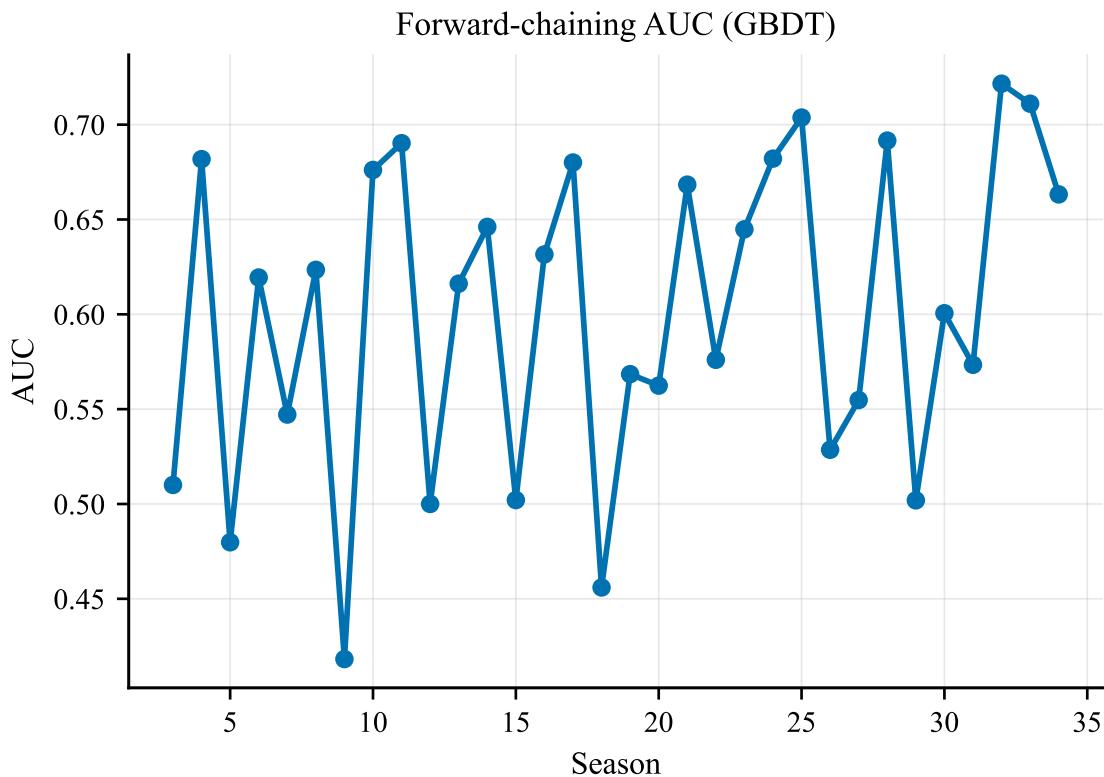


图 22: 分季 AUC 表现稳定 (前向链式验证)。

参考文献

- [1] COMAP. 2026 MCM/ICM Problem C: Dancing with the Stars (DWTS). Contest Problem Statement.
- [2] Smith, R. (1984). Efficient Monte Carlo procedures for generating points uniformly in polytopes. *Operations Research*.
- [3] Jaynes, E. T. (1957). Information theory and statistical mechanics. *Physical Review*.
- [4] Gelman, A., et al. (2013). *Bayesian Data Analysis*. CRC Press.
- [5] Moulin, H. (1988). *Axioms of Cooperative Decision Making*. Cambridge Univ. Press.

AI 使用报告

我们使用 AI 协助完成论文结构草稿、LaTeX 模板与方法表述润色；所有模型选择与解释均由团队复核并最终确认。

- 可复现性：代码、图表与指标均由提供数据自动生成。
- 环境：Miniforge + mcm2026，科学计算栈已固定版本。
- 过程留痕：运行日志与汇总指标可追溯每次实验。